

Отчёт - Чекпоинт 1: Сбор данных

1. Источники данных

Основным источником корпуса является arXiv.org. Мы используем официальное Python API (arxiv), что обеспечивает стабильный и автоматизированный доступ к PDF-статьям по выбранным научным направлениям Computation and Language (cs.CL), Artificial Intelligence (cs.AI), Machine Learning (cs.LG).

Дополнительный источник (для Web-RAG) - Tavily Search API, но он используется на следующих этапах.

Команда имеет доступ ко всем необходимым API-ключам и библиотекам.

2. Сбор данных

Данные собраны автоматически с использованием модуля data_ingestion:

1. Загрузка PDF:

- Скрипт `arxiv_downloader.py` выполняет поиск и скачивание статей.
- Все файлы сохраняются в папку: `data/raw/arxiv_pdfs/`

2. Конвертация PDF → текст:

- Модуль `pdf_to_text.py` извлекает текст из документов.
- Результат сохраняется в: `data/processed/texts/`

Все данные находятся в едином хранилище внутри `/data/`

3. Подготовка данных для RAG

Для дальнейшего использования данные полностью структурированы:

1. Chunking текста

Скрипт `chunker.py` разбивает каждый текст на перекрывающиеся чанки (1200 символов, `overlap 200`).
Итоговый корпус хранится в: `data/chunks/local/chunks.jsonl`

2. Векторизация

- Эмбединги SentenceTransformers сохраняются в: `data/chunks/local/embeddings.npy`
- ID документов - в: `data/chunks/local/doc_ids.txt`

3. Индексы retrieval

- **BM25**: `data/chunks/local/bm25_index.json`, `bm25_meta.json`
- **FAISS**: `data/faiss/local_dense.index`, `local_dense_meta.json`

Данные готовы к использованию локальным RAG, hybrid RAG и web RAG.

4. Документация в README

README содержит:

- описание источников данных,
- инструкции по сбору корпуса,

- структуру папок,
- команды запуска пайплайна,
- примеры данных.

5. Ссылка на сэмпл данных

Сэмпл чанков доступен в файле: `data/chunks/local/chunks.jsonl`

6. Объём данных

На момент отчёта собрано:

- **200 PDF** статей с arXiv,
- **13564 чанков** текста,
- **13564 эмбеддингов** в векторном хранилище,
- Полный BM25 и FAISS индексы поверх всего корпуса.